family-business

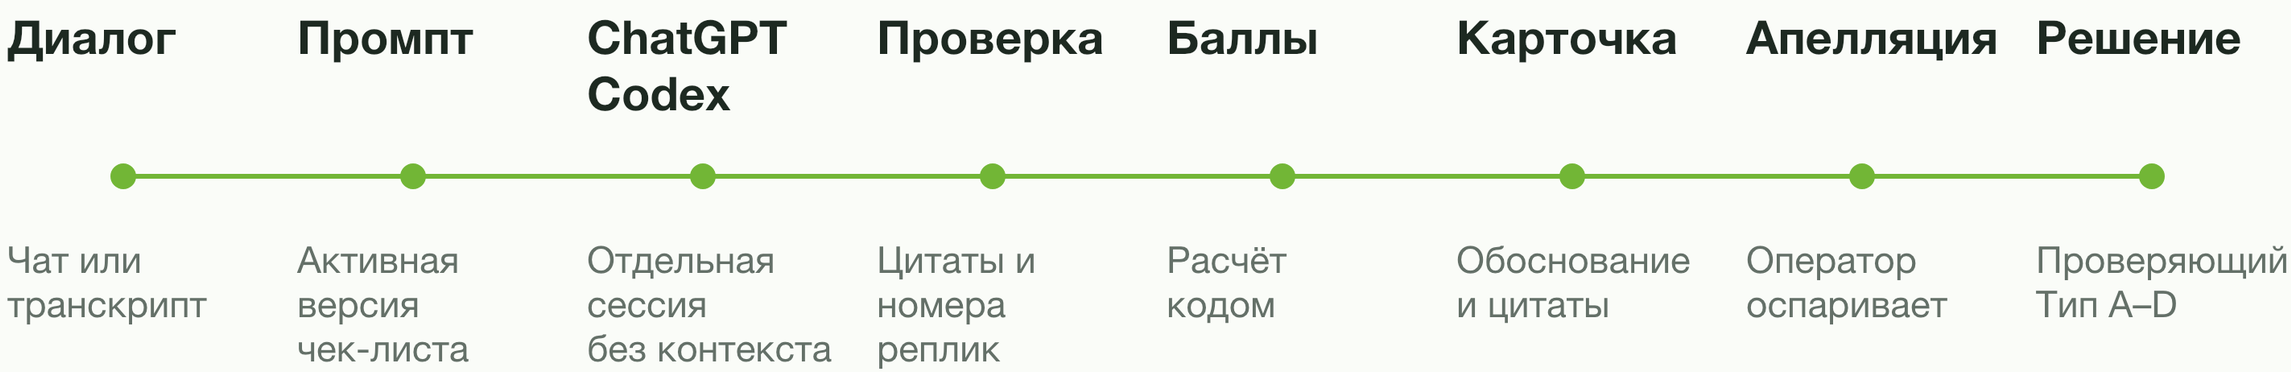
Freedom Quality

Платформа контроля качества диалогов

Исследование конфигураций, решения человека и обучение на апелляциях

Freedom Broker / CQA Hackathon

Как проходит оценка



Код учитывает веса и перераспределяет N/A

Флаг грубой ошибки отдельно. Решение проверяющего окончательное.

Исследование конфигураций

≈300 изолированных вызовов LLM, 16 прогонов

Модель	Вызовы	$/диалог	Совпадение	MAE
Haiku V1	1	0,004	70,0%	14,3
Sonnet V1	**1**	**0,052**	**82,5%**	**8,6**
Sonnet V2	4	0,106	82,5%	14,4
Sonnet V3	8	0,167	82,5%	12,9
Opus V1	1	0,107	90,0%	7,0

На нашем эталоне: 5 диалогов, 40 меток. Цена — API-эквивалент.

+7,5 п. п.

Opus против Sonnet V1

+$0,055 / диалог

≈$550 на 10 000 диалогов

Haiku → Sonnet: +12,5 п. п.

Повторяемость 97,5% / AUC самооценки 0,54–0,61

Ошибки модели в расчёте до 15,4 балла. Итог считает код.

Прогоны, метрики и альтернативы можно пересчитать на другом эталоне.

Открытая система, где решает человек

8

версий чек-листа

889

событий с цепочкой хешей

104

команды API

66

тестов

Модель и промпт

Провайдер, шаблон
Уточнения и прецеденты

Чек-лист

Добавление, правка, архив
Веса, шкалы и N/A

Решения и версии

Окончательное решение проверяющего
Активация только человеком

«Откуда ответ»: промпт, сырой ответ, версии и решения людей

Замкнутый цикл на решениях проверяющих

49 решений → 19 закономерностей → 5 предложений

47 групп копятся. Оркестратор за 61 с выявил 2 конфликта в нашем эталоне.

84,6% → 88,0%

Совпадение меток на нашем эталоне, 26 отложенных диалогов

MAE 11,5 → 9,6

В пределах ±5: 31% → 54%

Итерация 1: широкое правило c05. Человек сузил его в итерации 2.

Исправлено 10 / сломано 3. p = 0,09: направление ясное, выборка маленькая.

Контрольный набор: 10 чатов за 10 минут

10 мин

5 параллельных сессий Codex

results/dev/results.json

65 записей, все ok

results/prod/results.json

10 записей, все ok

Контроль по версии v8, которую человек активировал после цикла

Формат проверен. Далее — живое демо платформы.