family-business

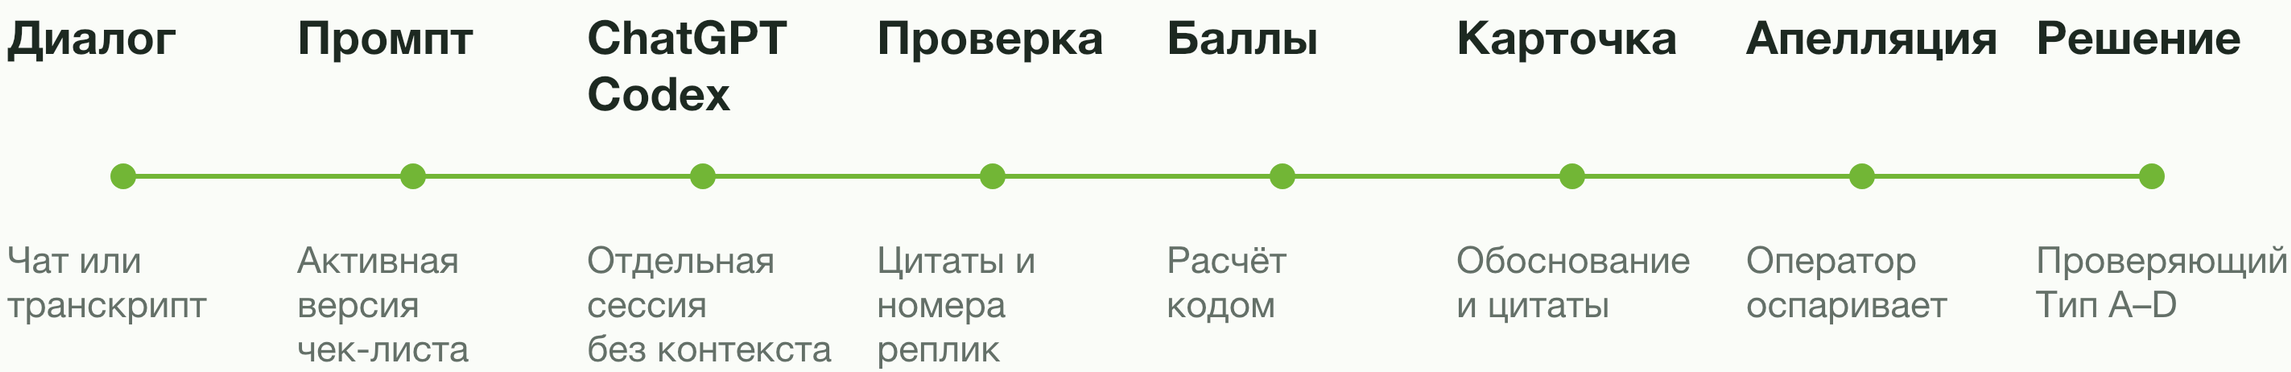
Freedom Quality

Платформа контроля качества диалогов

Оценка с доказательствами и окончательным решением человека

Freedom Broker / CQA Hackathon

Как проходит оценка



Код учитывает веса и перераспределяет N/A

Флаг грубой ошибки отдельно. Решение проверяющего окончательное.

Правила меняются под контролем человека

Замкнутый цикл обучения

Решения проверяющих → Закономерности с уверенностью → Предложения оркестратора → **Принятие человеком** → Регрессия на отложенной части → Активация версии

Чек-лист

Критерии, веса и версии
Архив вместо удаления
Пересчёт без LLM

«Откуда ответ»

Промпт, сырой ответ, версии
Решения людей
История с цепочкой хешей

Очередь и роли

Сомнительные оценки
Администратор, руководитель
Проверяющий, оператор

Пересчёт использует имеющиеся ответы. Новые критерии требуют оценки моделью.

Один вызов на диалог

Дробление не показало прироста в наших пилотах

Sonnet 5.5	На диалог	API-эквивалент
V1 Монолит	**1 вызов**	**$0,052**
V2 По секциям	4 вызова	**$0,106**
V3 По критериям	8 вызовов	**$0,167**

Выбор модели оказался важнее разделения задачи

Предварительный эксперимент: 5 диалогов. Стоимость без скрытых reasoning-токенов.

R-base: качество и время

84,4%

совпадения меток на нашем эталоне

65 диалогов DEV

10,6

MAE итогового балла

100%

дословных цитат

≈140 с / диалог

4 параллельные сессии

10 диалогов ≈ 10 мин при лимите 60 мин

Оценка времени по R-base. Эталон: наша разметка DEV с GPT-помощником.

Цикл обучения: две итерации

26 отложенных диалогов, наш эталон

84,6% → 88,0%

совпадения меток до и после второй итерации

MAE 11,5 → 9,6

В пределах ±5 31% → 54%

Исправлено 10 / сломано 3

Итерация 1: слишком широкое правило c05. Человек сузил его для итерации 2.

p = 0,09. Направление ясное, выборка маленькая. Статистическая значимость не достигнута.